

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

DIPLOMSKI RAD br. 959

**Aplikacija za interaktivnu pomoć
penjačima po stijenama uporabom
proširene stvarnosti**

Adrian Cvijanović

Zagreb, lipanj 2025.

SADRŽAJ

| | |
|------------------------------------------------------------------------------------|-----------|
| 1. Uvod | 1 |
| 2. Računalni vid u prepoznavanju penjačkog smjera | 3 |
| 2.1. Detekcija i opis značajki (engl. feature detection and description) | 5 |
| 2.1.1. Odabir algoritma detekcije značajki | 5 |
| 2.1.2. SIFT algoritam | 5 |
| 2.2. Uparivanje značajki (engl. feature matching) | 7 |
| 2.3. Homografija i transformacija perspektive | 9 |
| 3. Zaključak | 12 |
| 3.1. Sažetak rada i ostvareni rezultati | 12 |
| 3.2. Smjernice za budući razvoj | 12 |
| 3.2.1. Poboljšanja procesa prepoznavanja | 12 |
| 3.2.2. Integracija topografskih prikaza | 13 |
| Literatura | 14 |

1. Uvod

Digitalna tehnologija obuhvaća gotovo sve aspekte ljudskog života, od komunikacije, poslovanja do zabave i znanja. Rekreativne aktivnosti i sportovi koji su se oslanjali na fizičku opremu i materijale sve više usvajaju digitalne alate koji proširuju mogućnosti i količinu informacija koje korisnici mogu dobiti. Sportsko penjanje, kao aktivnost koja spaja fizičku spremnost i boravak u prirodi, predstavlja primjer aktivnosti koja se može proširiti digitalnim alatima.

Sportsko penjanje i sroдна disciplina *bouldering* posljednjih su desetljeća doživjeli eksponencijalni rast u popularnosti, privlačeći sve veći broj zainteresiranih ljudi kako u specijalizirane penjačke dvorane, tako i na stijene u prirodi. Na Olimpijskim igrama 2020. godine u Tokiju sportsko penjanje je po prvi put uvršten u program čime je sport dobio globalnu pozornost i dodatno potaknuo interes javnosti. Olimpijskim igrama 2024. godine u Parizu popularnost sporta je još više porasla. Prema članku iz *The Oxford Blue*, dok se vrijednost globalnog tržišta penjačkih dvorana procjenjuje na 117.61 milijardi dolara do 2031. godine [3]. S rastom zajednice, raste i potreba za kvalitetnim, dostupnim i preciznim informacijama o penjačkim lokacijama i smjerovima.

Tradicionalno, glavni izvor informacija za penjače koji žele penjati na stijenama u prirodi su tiskani penjački vodiči. Ovi vodiči sadrže detaljne opise penjačkih lokacija, karte pristupa, kao i skicirane prikaze stijene ili često nazivane *topo* s ocrtanim linijama penjačkih smjerova, njihovim nazivima i težinama. Iako su desetljećima bili nezamjenjivi alat, tiskani vodiči imaju ograničenja. Neki od ključnih nedostataka su statičnost i zastarijevanje podatka, nepraktičnost nošenja, nekonzistentnost između različitih izdanja te, najvažnije, poteškoće u interpretaciji dvodimenzionalnih skica na stvarnoj, trodimenzionalnoj stijeni zbog liminitiranog broja slika koji se mogu staviti u vodič.

S pojavom interneta i pametnih telefona, razvile su se digitalne platforme i mobilne aplikacije koje su djelomično riješile problem dostupnosti i ažurnosti podataka. One omogućuju centralizirano prikupljanje informacija, korisničke komentare i lakšu pretragu. Osim toga, nude i napredne funkcionalnosti poput vođenja osobnog dnevnika uspona, analize statistike, praćenja napretka i povezivanja s drugim penjačima. Una-

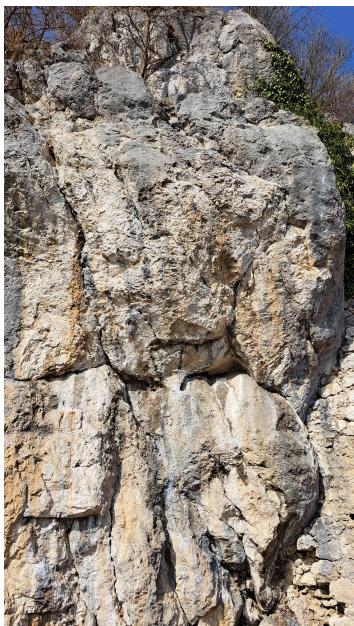
toč tim prednostima, digitalna rješenja nisu bez nedostataka. Unatoč tim prednostima, i digitalna rješenja imaju svoja ograničenja. Ključni nedostaci uključuju oslananje na statične, dvodimenzionalne prikaze koji ne rješavaju problem interpretacije na terenu, kao i praktične izazove poput ovisnosti o trajanju baterije i dostupnosti internetskog signala na udaljenim lokacijama.

Navedeni nedostaci postojećih alata stvaraju potrebu za rješenjem koje pokriva njihove nedostatke. Cilj je iskoristiti mobilnu tehnologiju kako bi se stvorilo rješenje koje bi minimiziralo navedene nedostatke. Ideja je omogućiti penjačima da jednostavnim usmjeravanjem kamere mobilnog uređaja prema stijeni dobije vizualnu informaciju o položaju i nazivima smjerova izravno u stvarnom okruženju korištenjem tehnologije proširene stvarnosti. Takav pristup ne samo da štedi vrijeme i smanjuje frustracije, već i omogućuje sigurnije iskustvo penjanja.

2. Računalni vid u prepoznavanju penjačkog smjera

Prepoznavanje specifičnih objekata sa slike, u ovom slučaju prepoznavanje penjačkih smjerova na slici stijene, zahtijeva primjenu metoda koje su otporne na promjene u osvjetljenju, udaljenosti i kutu gledanja. Pristupi koji se temelje na uspoređivanju piksela slike su neefikasni i nepouzdani jer su osjetljivi na spomenute varijacije. Zbog toga se koriste robusnije metode temeljene na detekciji i opisu lokalnih značajki (eng. *feature-based methods*). Temeljna ideja je pronaći jedinstvene, stabilne i ponovljive točke na slici, značajke, te ih iskoristiti za usporedbu i prepoznavanje.

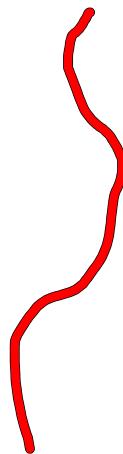
Cjelokupni proces prepoznavanja penjačkog smjera pomoću detekcije značajki zahtijeva tri komponente, referentnu sliku penjačkog smjera, referentnu sliku linije penjačkog smjera te sliku stijene dobivene sa kamere mobilnog uređaja (slika 2.1).



(a) Slika stijene dobivena sa kamere



(b) Referentna slika stijene



(c) Referentna slika linije smjera

Slika 2.1: Tri slike potrebne za prepoznavanje penjačkog smjera

Referentna slika penjačkog smjera te referentna slika linije penjačkog smjera moraju biti iste dimenzije. Proces se može se raščlaniti na sljedeće korake. Prvi korak je detekcija i opis značajki, gdje se na referentnoj slici, unaprijed pripremljenoj slici stijene, i slici dobivenoj sa kamere pronađe ključne točke te se za svaku ključnu točku generira jedinstveni numerički opis, odnosno deskriptor. Potom se uparuju značajke između slika uspoređujući deskriptore, tipično koristeći algoritam poput *FLANN Matcher*. Te uparene značajke koriste se u trećem koraku, gdje se računa procjena geometrijske transformacije. Računa se matematički model - homografija, koja opisuje kako je slika stijene dobivena sa kamera rotirana, skalirana i perspektivno izobličena u odnosu na referentnu sliku. Konačno provodi se primjena transformacije, gdje se izračunati model koristi kako bi se referentna slika linije penjačkog smjera preslikala na sliku dobivenu sa kamere. Time se postiže željeni efekt vizualizacije penjačkog smjera u stvarnom vremenu.

U ovom poglavlju detaljno se obrađuju svi koraci procesa prepoznavanja penjačkog smjera, od detekcije značajki, preko uparivanja značajki do transformacije perspektive, koristeći prave slike penjačkog smjera i OpenCV biblioteku.

2.1. Detekcija i opis značajki (engl. feature detection and description)

2.1.1. Odabir algoritma detekcije značajki

Za uspješno prepoznavanje objekta potrebno je odabrati algoritam koji može detektirati značajke koje su invarijantne na promjene u okolini. U domeni detekcije značajki postoji nekoliko algoritama, koji se razlikuju po brzini i preciznosti detekcija. Primjerice SURF (eng. *Speeded Up Robust Features*) dizajniran je kao brža aproksimacija SIFT-a, koristeći integralne slike s ubrzanje izračuna. ORB (eng. *Oriented FAST and Rotated BRIEF*), koji kombinira brži detektor kutova FAST s binarnim deskriptorima BRIEF, što ga čini iznimno popularnim za uvjete mobilnih uređaja s ograničenim resursima. Unatoč manjoj brzini, u ovom radu se proučava i koristi SIFT, koji je razvio David Lowe [1]. Odluka se temelji na njegovoj preciznosti i robusnosti u odnosu na ostale algoritme, unatoč što zahtijeva više resursa. SIFT generira visokodimenzijske deskriptore koji omogućuju pouzdano prepoznavanje kompleksnih površina poput prirodne stijene.

Iako su u modernom računalnom vidu pristupi temeljeni na dubokom učenju (eng. *deep learning*) postali popularniji, njihova primjena u ovom problemu nije praktična radi količine potrebnih podataka za treniranje. U kontekstu ovog rada, to bi značilo da za svaki penjački smjer trebalo bi biti mnogo slika iz različitih kutova, udaljenosti i uvjeta osvjetljenja, te ih ručno kategorizirati. S obzirom da je sustav dinamičan i korisnici su oni koji dodaju penjačke smjerove, za svaki novi unos podatak potrebno bi bilo ponovno trenirati model. Takav proces prikupljanja podataka i treniranja modela je iznimno zahtjevan i nepraktičan. SIFT i drugi algoritmi detekcije značajki funkcioniраju na principu učenja iz jednog primjera, tj. potrebna je samo jedna referentna slika za kasnije prepoznavanje.

2.1.2. SIFT algoritam

Rad SIFT algoritma može se podijeliti u četri faze. U prvoj fazi se detektiraju ekstremi u prostoru skale. Kako bi se postigla invarijantnost u skali, algoritam ne pretražuje značajke samo na originalnoj slici, već u trodimenzionalnom prostoru skale koji se generira postupnim zamalućivanjem i skaliranjem originalne slike primjenom Gaussovih filtera s rastućom standardnom devijacijom. Cijeli proces se često provodi u oktavama, gdje se nakon određenog broja zamalućenja slika smanjuje na pola veličine i proces se

ponavlja. Time se dobivaju različite verzije slike, od oštре do zamućene, simulirajući pogled na objekt s različitih udaljenosti. Za efikasnu detekciju stabilnih točaka koje su neovisne o skali, SIFT koristi aproksimaciju Laplaceove-Gaussove funkcije zvanu razlika Gaussovih funkcija (eng. *Difference of Gaussians, DoG*). DoG slike dobivaju se oduzimanjem dviju susjednih, različito zamućenih slika unutar iste oktave. Potencijalne ključne točke lociraju se kao lokalni minimum ili maksimum u DoG prostoru. Točka se smatra lokalnim ekstremom ako je njena vrijednost veća ili manja od svih osam susjednih piksela na istoj DoG slici, te svih 9 susjednih piksela na DoG slici iznad ili ispod nje - ukupno 26 susjeda.

Kandidati dobiveni u prethodnoj fazi trebaju se dalje filtrirati kako bi se odbacile nestabilne točke. Prvo se interpolira vrijednosti sub-piksela gdje se nalazi lokacija ekstrema. Ideja iza interpolacije je da se želi povećati preciznost i stabilnost ključnih točaka. Preciznije točke omogućuju bolje uparivanje te bolje naknadno korištenje značajnih točka, poput izračuna homografije. Nakon interpolacije primjenjuje se eliminacija točaka koje leže na rubovima. Rubovi su detektirani kao ekstremi, no točke na samom rubu su nepouzdane za precizno uparivanje jer je njihova lokacija duž samog ruba slabo definirana.

Kako bi se postigla invarijantnost na rotaciji, svakoj preostaloj ključnoj točki dodjeljuje se jedna ili više orijentacija. Orijentacija se izračunava na temelju lokalnog gradijenta slike u okolini ključne točke koristeći magnitudu i smjer gradijenta svakog piksela. Za svaku ključnu točku kreira se histogram orijentacija gradijenta s 36 spremnika koji svaki pokriva kut od 10 stupnjeva. Svaki unos u histogram uključuje u račun magnitudu gradijenta te udaljenost od centra ključne točke. Ako je piksel na oštroj kontrasnoj liniji magnituda gradijenta biti će veća, također ako je piksel na rubu okoline, magnituda će biti manja i time utjecaj te orijentacije manji. Vrh tog histograma definira dominantnu orijentaciju ključne točke. Ako postoji više od jedne orijentacije, tj. ako postoji orijentacija koja je veća od 80% od dominantne orijentacije, tada se kreira nova ključna točka sa istim položajem i skalom, ali s drugom orijentacijom. Time se povećava stabilnost uparivanja na mjestima s kompleksnim gradijentom.

Poslijednji korak je stvaranje jedistvenog numeričkog deskriptora za svaku ključnu točku. Oko ključne točke uzima se 16x16 piksela te se rotira u skladu s dominantnom orijentacijom čime se postiže nezavisnost rotacije. Rotirana okolina se zatim dijeli na 4x4 podregije. U svakoj podregiji računa se histogram orijentacija gradijenta s 8 spremnika i vrijednosti iz svih 16 histograma spaja se u jedan 128-dimenzionalni vektor te se vektor normalizira kako bi se smanjila ovisnost o osvjetljenju.



(a) Referentna slika penjačkog smjera

(b) Slika s kamere mobilnog uređaja

Slika 2.2: Detekcija značajki SIFT algoritmom

Izlaz iz SIFT algoritma je skup detektiranih značajki, tj. njen položaj, skala, orientacija i 128-dimenzionalni deskriptor. Cijeli proces SIFT algoritma provodi se za referentnu sliku penjačkog smjera te slike dobivene sa kamere mobilnog uređaja. Na slici 2.2 prikazan je primjer detekcije značajki SIFT algoritmom za referentnu sliku penjačkog smjera i sliku dobivenu sa kamere mobilnog uređaja. Radi preglednosti prikazuju se samo značajke koje obuhvaćaju veću površinu.

2.2. Uparivanje značajki (engl. feature matching)

Nakon što se odrede SIFT značajke na obije slike, potrebno je pronaći podudaranja među njima. Proces se svodi na pronalaženje parova deskriptora koji su međusobno najsličniji u visokodimenzionalnom prostoru. Postoji nekoliko metoda za mjerjenje sličnosti deskriptora.

Prva metoda je korištenje *brute force* algoritma. Sličnost između dva 128-dimenzionalna SIFT deskriptora mjeri se koristeći Euklidsku udaljenost formulom

$$d(d_1, d_2) = \sqrt{\sum_{i=1}^{128} (d_1[i] - d_2[i])^2} \quad (2.1)$$

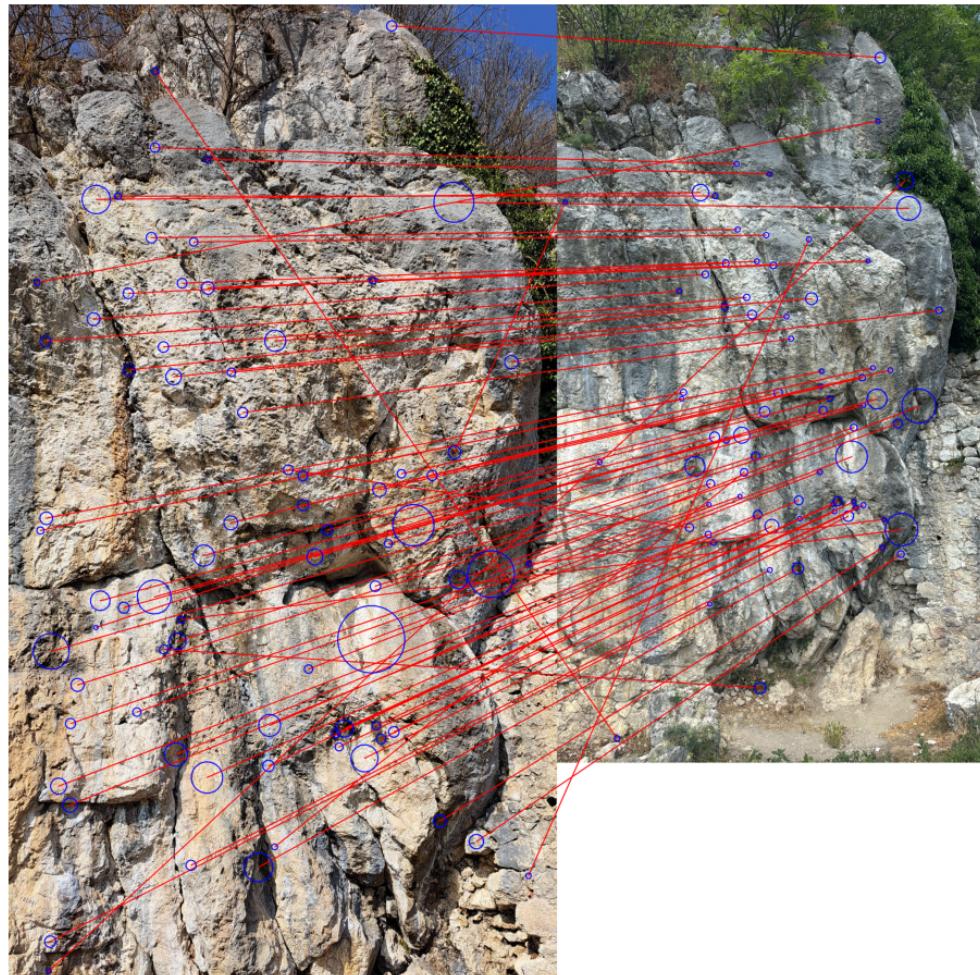
gdje su d_1 i d_2 dva 128-dimenzionalna SIFT deskriptora. Manja Euklidska udaljenost predstavlja veću sličnost između deskriptora, odnosno između lokalnih struktura slike koje oni predstavljaju. Kada bi se uparivanje izvodilo jednostavnim pronalaskom para sa minimalnom udaljenosti došlo bi do velikog broja pogrešnih podudaranja. Zbog toga se koristi algoritam zvan Loweov test omjera [1]. Umjesto da se traži samo jedan, za svaki deskriptor s referentne slike pronalaze se dva najbliža susjeda na slici sa kamere. Ako je omjer udaljenosti između najbližeg i drugog najbližeg susjeda manji od koeficijenta t , deskriptor se smatra valjanim podudaranjem. Ovo se može opisati formulom

$$\frac{d(d_1, d_2)}{d(d_1, d_3)} < t \quad (2.2)$$

gdje su d_1 , d_2 i d_3 tri 128-dimenzionalna SIFT deskriptora, d je Euklidska udaljenost, a t je koeficijent koji se koristi za filtriranje pogrešnih podudaranja. Uobičajena vrijednost za prag t je između 0.7 i 0.8. Ovaj test provjerava je li podudaranost nedvosmislena, odnosno ako je najbliži susjed znatno bliži od drugog onda je značajka jedinstvena i podudarnost je vjerojatno ispravna. Ako to nije istina onda to ukazuje na dvosmislenost i takva podudaranost se odbacuje kao nepouzdana.

Unatoč što ovaj algoritam daje dobre rezultate, njegova vremenska kompleksnost ga čini nepraktičnim za rad u stvarnom vremenu. Kako bi se ubrzao proces, često se koriste algoritmi za aproksimativnu pretragu najbližih susjeda koji se oslanjaju na efikasne strukture podataka za organizaciju visokodimenzionalnih vektora. Jedna od takvih struktura je *k-d stablo*. K-d stablo je prostorna podatkovna struktura koja rekurzivno dijeli prostor u polovične podprostore čime postiže brzu eliminaciju velikih dijelova prostora pretrage. Unatoč njenoj efikasnosti u prostorima niske dimenzionalnosti, njena primjena u visokodimenzionalnim prostorima nije učinkovita, što je problematično za 128-dimenzionalne SIFT deskriptore. Zato je za SIFT deskriptore bolja tehnika LSH (eng. *Locality-Sensitive Hashing*) koja se oslanja na hash funkcije za brzo pronalaženje sličnih vektora u visokodimenzionalnom prostoru. U praksi se takvi algoritmi ne implementiraju ručno već se koriste gotove biblioteke koje nude bolja rješenja. Jedna od takvih biblioteka je *FLANN* (eng. *Fast Library for Approximate Nearest Neighbors*) koja implementira više različitih algoritama, uključujući i k-d stablo i LSH [2]. Bitno je navesti kako u sklopu OpenCV implementacije FLANN-a nije

moguće koristiti LSH algoritam jer je LSH algoritam implementiran samo za binarne deskriptore. Prednost FLANN-a je u tome što može automatski odabrati najprikladniju strukturu podataka i parametre pretrage na temelju podataka i odabranih kompromisa brzine ili preciznosti. Tim algoritmima i bibliotekama se postižu veće brzine uz minimalne gubitke u preciznosti naspram *brute force* algoritma.



Slika 2.3: Uparivanje značajki SIFT algoritmom

Na slici 2.3 prikazan je primjer uparivanja značajki SIFT algoritmom za referentnu sliku penjačkog smjera i sliku dobivenu sa kamere mobilnog uređaja.

2.3. Homografija i transformacija perspektive

Rezultat procesa uparivanja značajki je skup parova odgovarajućih točaka između referentne slike i slike dobivene sa kamere, no taj skup gotovo uvijek sadrži i određeni broj pogrešnih podudaranja. Te pogreške nastanu zbog dvostrislenosti ili nesavršenosti

SIFT deskriptora. Kako bi se uspostavila pouzdana geometrijska veza između dviju slika potrebno je pronaći matematički model koji opisuje transformaciju tih slika, ali na način koji je robustan na prisutnost tih pogrešnih parova. Takav model je homografija.

Homografija je projektivna transformacija u 2D prostoru koja preslikava točke iz jedne ravnine u drugu. U ovom slučaju te ravnine su referentna slika i slika dobivena sa kamere. Homografija se može opisati 3×3 matričnom jednadžbom

$$s * \begin{pmatrix} x' \\ y' \\ 1 \end{pmatrix} = \begin{pmatrix} h_1 & h_2 & h_3 \\ h_4 & h_5 & h_6 \\ h_7 & h_8 & h_9 \end{pmatrix} \begin{pmatrix} x \\ y \\ 1 \end{pmatrix} \quad (2.3)$$

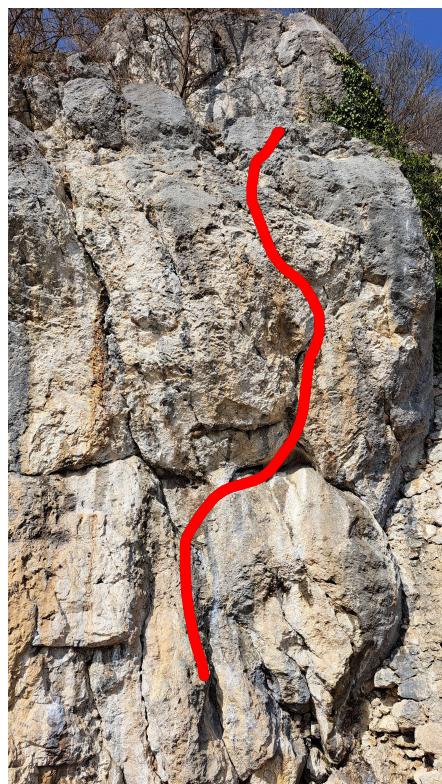
gdje su x i y koordinate točke na referentnoj slici, a x' i y' koordinate točke na slici dobivenoj sa kamere. s predstavlja faktor skale tj. s je posljedica korištenja homogenih koordinata i predstavlja treću komponentu rezultirajućeg vektora prije normalizacije. Faktor s osigurava da jednadžba vrijedi u projektivnom prostoru. Matrica H je homografska matrica koja se sastoji od 9 koeficijenata, no h_9 je tipično postavljen na 1 što znači da matrica ima 8 stupnjeva slobode. Za njen izračun potrebno je poznavati barem 4 odgovarajuće točke na referentnoj i slici dobivenoj sa kamere, pod uvjetom da su točke nekolinearne. Budući da za izračun homografije potrebno je samo četri para točaka, a iz procesa uparivanja dobije se znatno više parova, potrebno je odabrati najbolje parove na način da se također eliminira utjecaj pogrešnih podudaranosti. Za rješavanje ovog problema koristi se RANSAC (eng. *Random Sample Consensus*) algoritam. RANSAC je iterativni algoritam koji se sastoji od sljedećih koraka. Prvo se nasumično odabire minimalni podskup podataka potreban za izračun homografije, odnosno četri para uparenih točaka. Na temelju tih nasumičnih točaka izračunava se preliminarna homografija H . Potom se ta preliminarna homografija testira na način da se ta matrica primjenjuje na sve ostale točke iz početnog seta podataka i određuje se udaljenost između izračunate točke i prave točke iz seta. Ako je ta udaljenost manja od predefiniranog praga onda se taj par smatra podudaranim s modelom. Cijeli ovaj postupak se ponavlja veliki broj puta. Na kraju se odabire matrica H koja je u jednoj od iteracija dobila najveći broj podudaranja s modelom. Korištenjem ovog algoritma osigurava se da pogrešne podudaranosti budu efikasno ignorirane jer se neće uklopiti u jedan konzistentan geometrijski model.

Primjer matrice homografije dobivene iz procesa uparivanja značajki prikazanog na slici 2.3 može izgledati ovako:

$$H = \begin{pmatrix} 0.6298 & 0.0750 & 412.29 \\ 0.0065 & 0.7816 & 271.09 \\ 0.000000280 & 0.0000741 & 1 \end{pmatrix} \quad (2.4)$$

Ova matrica H transformira koordinate točaka s referentne slike penjačkog smjera na sliku dobivenu sa kamere, uzimajući u obzir rotaciju, translaciju, skaliranje i perspektivnu deformaciju. Vrijednosti u matrici su stvarni primjer dobiven iz procesa uparivanja značajki za konkretni slučaj prikazan u prethodnom poglavlju.

Kada je pronađena matrica H s njom se može postići transformacija perspektive između dviju slika. Korištenjem homografije moguće je preslikati referentnu sliku linije penjačkog smjera na sliku dobivenu sa kamere koristeći OpenCV biblioteku te algoritam *warpPerspective*. Kao izlaz, generira se nova slika na kojoj je sadržaj perspektivno izobličen u skladu s matricom H .



Slika 2.4: Rezultirajuća slika transformirane linije penjačkog smjera

Rezultirajuća slika transformirane linije penjačkog smjera tada se može iscrtati preko slike dobivene sa kamere (slika 2.4). Budući da je homografija izračunata na temelju značajki sa stijene, transformirana linija će se precizno poklapati s geometrijom stijene u trenutnom pogledu kamere čime se postiže efekt proširene stvarnosti.

3. Zaključak

3.1. Sažetak rada i ostvareni rezultati

Problem identifikacije penjačkih smjerova na terenu, koji proizlazi iz ograničenja tradicionalnih tiskanih i postojećih digitalnih vodiča, predstavlja je temeljnu motivaciju za ovaj diplomski rad. Cilj je bio implementirati cijelovit softverski sustav "Alpinity" koji koristi tehnologije računalnog vida i proširene stvarnosti kako bi riješio taj problem.

Uz rad razvijen je i funkcionalni digitalni penjački vodič koji se sastoji od pozadinskog sustava, web aplikacije i mobilne aplikacije za iOS. Implementirana je funkcionalnost koja korisniku omogućuje da, usmjeravanjem kamere prema stijeni, u stvarnom vremenu dobije vizualnu informaciju o položaju penjačkog smjera. Testiranje u realnim uvjetima potvrđilo je da je odabrani algoritamski pristup, temeljen na SIFT značajkama i procjeni homografije, funkcionalan i sposoban za prepoznavanje smjerova s različitim vizualnim karakteristikama.

Međutim, testiranje i vrednovanje je također otkrilo i ograničenja implementacije, prvenstveno u vidu latencije i povremene nestabilnosti detekcije, što je posljedica računskog opterećenja na mobilnom uređaju. Unatoč tim ograničenjima, rad je demonstrirao da je koncept vizualizacije smjerova pomoću proširene stvarnosti izvediv i da nudi potencijal za unapređenje korisničkog iskustva digitalnih penjačkih vodiča.

3.2. Smjernice za budući razvoj

3.2.1. Poboljšanja procesa prepoznavanja

Iako je razvijeni sustav funkcionalan, postoji prostor za daljnja poboljšanja. U nastavku se razmatraju područja za budući razvoj, s posebnim naglaskom na unapređenje procesa prepoznavanja.

Uočeni problemi latencije i vizualnog šuma mogu se ublažiti implementacijom optimizacija. Namještanjem SIFT parametara i povećanjem minimalnog broja potrebnih

parova značajki mogli bi pojačati preciznost detekcije i smanjiti vizualni šum. Trenutni sustav izračunava homografiju neovisno za svaki obrađeni kadar, što može dovesti do nestabilnosti i pogrešne detekcije. U budućnosti bi se moglo implementirati provjera koeficijenta matrice homografije kako bi se osiguralo da matrica ne transformira sliku u nestvarne oblike ili koristeći druge apstraktnije metode provjere matrice. Ako je dobivena matrica pala te testove onda se ne bi koristila za transformaciju slike i time se ne bi detektirala linija penjačkog smjera.

Nadalje, obrada zamućenih kadrova, nastalih brzim pokretom kamere, bespotrebno troši resurse i može dovesti do pogrešnih podudaranosti. Moguće je implementirati pred-procesni korak za filtriranje zamućenih kadrova. Primjerice, izračunom varijance Laplaceove transformacije slike može se procjeniti razina oštine, te bi se kadrovi koji ne zadovoljavaju minimalni prag oštine mogli ne dodati u spremnik kadrova i time ne bi se slali na SIFT obradu.

Konačno, trenutna arhitektura dizajnirana je za prepoznavanje jednog, unaprijed odabranog smjera. Značajno unapređenje bilo bi omogućiti sustavu detekciju više smjerova, recimo jednog sektora, istovremeno. To bi zahtjevalo da se deskriptori s kamere uspoređuju s cjelokupnom bazom deskriptora za sve smjerove u sektoru. Iako je ovo računski znatno zahtjevnije, pružilo bi bolje korisničko iskustvo.

3.2.2. Integracija topografskih prikaza

Testiranje je pokazalo da su referentne slike snimljene sa tla korisne za identifikaciju početka smjera, ali često ne mogu obuhvatiti cijeli tijek smjera, pogotovo kod dužih smjerova. S druge strane, klasične topo skice, iako apstraktne, pružaju jasan pregled cijele linije. Budući razvoj mogao bi uključivati hibridni pristup. Nakon što aplikacija uspješno prepozna penjački smjer, korisniku bi se mogla ponuditi opcija prebacivanja na 2D topo prikaz tog sektora, s jasno istaknutim prepoznatim smjerom. Time bi se kombinirale prednosti oba svijeta, precizna identifikacija na terenu i jasan pregled cijelog smjera pomoću topografske skice.

LITERATURA

- [1] D.G. Lowe. Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, siječanj 2004.
- [2] OpenCV. Opencv: Feature matching. URL https://docs.opencv.org/4.x/dc/dc3/tutorial_py_matcher.html.
- [3] The Oxford Blue. Why does everyone suddenly want to rock climb? <https://theoxfordblue.co.uk/why-does-everyone-suddenly-want-to-rock-climb/>, siječanj 2025. Pristupljeno 7. lipnja 2025.